基於仿生神經分工架構之生成式 AI 自主無人機研究

作者:謝易宸

(一)摘要

隨著無人機在現代戰爭與偵蒐等任務的地位日益重要，具備「全自主決策」能力的無人機已成為各國著重發展的技術。然而，傳統 End-to-End AI 模型高度依賴巨量資料且決策缺乏透明度；而 LLM 雖然有優秀的決策推論能力，但擁有「幻覺（Hallucination）」與「通訊高延遲」兩大缺陷，使其難以直接應用馬達數值的輸出與控制。如何讓無人機的自主系統擁有 LLM 的智慧，卻能避免其失控風險，為本研究的核心之一。

為解決上述難題，本計畫提出一種創新的「仿生神經分工三層式控制架構（Hierarchical Control Architecture）」，將系統劃分為負責高階邏輯的大腦 (Layer 1, Cloud LLM)、負責行為規劃與安全檢查的神經中樞 (Layer 2)，以及負責即時反射控制的小腦（Layer 3）。採用「雲端-本地協同」的設計，將高算力需求的 OpenAI GPT-4o 模型部署於雲端，並結合 Prompt Engineering 與 RAG 檢索機制與演算法的優化來提升決策精準度。

考量資源上的限制與實際風險，本計畫採用 SITL 驗證，利用 Microsoft AirSim 模擬器建構高擬真環境、無人機硬體、無人機上的感測器與感測數據回傳等，在本計畫中主要我們專注於 AI 決策邏輯與自動化系統的驗證。在環境感知方面，採用預先標註之靜態語意地圖 (Pre-processed Semantic Map) 取代真實的衛星遙測，著重於驗證 Layer 1 如何讀取地圖資訊並結合情節記憶 (Episodic Memory) 進行決策，確保系統在開發後具備實際運用於真實無人機的可行性。

本研究預期透過開發本地端的「共享情報戰情室」與 Layer 2 的地理圍欄機制，能有效從源頭攔截 LLM 的幻覺，並藉由情節記憶庫的閉環反饋，賦予無人機從經驗中學習的能力。本計畫希望不只解決了生成式 AI 難以落地於無人機的技術難題，更提出了一套低成本、高可靠度且具備持續學習能力的通用架構，達成具備自主思考、偵蒐能力的無人機系統。

(二)研究動機與目的

對於未來理想的無人載具(包含無人機)自主系統應具備理解複雜意圖、思考推論並進行自主智慧化的飛行規劃與控制功能，以實現無需人為干預的全自主控制[1-2]。然而，傳統無人機自動化依賴預先編寫好的程式碼、腳本或其他事前的系統設定編寫，缺乏對於未知環境的適應力以及不同環境上的通用性。另外，越需要執行複雜的任務越是要花費大量的訓練時間與收集大量的訓練資料，單純依賴端到端（End-to-End）的 AI 模型（如 CNN 或 Transformer）則在控制的輸出上，缺乏透明的可解釋性且難以提供可驗證的安全性保障。LLM

雖然具備優良的意圖理解與常識推理能力，能輸出接近人類的決策推論和思考能力，但其非固定性的輸出與潛在的生成幻覺問題（Hallucinations）對於飛行安全構成極大風險[3-5]。

因此，我們希望在系統架構中增加以下功能與設計：

1. 解決 LLM 生成幻覺與延遲：透過 RAG 資料庫與驗證機制，過濾錯誤指令。
2. 實現自適應與動態策略執行：設計 Layer 2 Behavior Planner 系統，將抽象策略、決策轉化為具體的航點、飛行路徑規劃與控制動作，還有對於 LLM 的輸出進行檢查，如果偵測到異常與風險，直接駁回 Layer 1 的決策。
3. 飛行安全：設計 Layer 3 Low-Level Flight Controller（仿小腦的功能)系統架構，主要負責感測飛行時狀態的數據(如深度空間相機感測數值與 IMU 數據)以及執行底層高頻率的飛行避障與姿態控制。
4. 建立閉環式學習機制：設計情節記憶資料庫，記錄無人機在飛行時的狀況，主要功能為了使 Layer 1 的決策與 Layer 2 的規劃不會重複犯錯（如重複誤判物體、不安全的飛行高度和重複飛行已執行偵蒐過的區域）。

(三)文獻回顧與探討

在自主系統的研究中，分層控制架構已被廣泛討論。為了模仿生物對於認知而產生行動的架構，Yuan (2025)、Chen (2025) 與 Vorobiov (2025) 等學者提出了將高層邏輯推理與低層物理控制分開的三層式架構。傳統方法上，多將感知與決策分離而卻也缺乏語義理解能力。近年來，普渡大學、麻省理工學院與多倫多都會大學等研究機構開始嘗試著將 LLM 整合至機器人系統，例如利用 LLM 進行符號規劃（Symbolic Planning）與代碼生成，以解決複雜任務[6-8]。

針對高速在三維空間飛行的無人機，必須擁有即時（Real-time）的場景應對能力。人工勢場法（Artificial Potential Field, APF）在路徑規劃上具有運算量小的優勢，適合底層避障控制；然而 APF 容易陷入受到的「引力」與「斥力」剛好互相抵銷，導致合力為零（Net Force = 0)，這種狀況稱為局部極小值(Local Minima)，針對此類狀況，Wu 等人(2025)結合 LLM 與強化學習解決針對複雜風場的自適應導航[9]，而 Jin 等人(2025)則利用強化學習優化 APF，有效協助系統解決極小值問題，並顯著強化了目標搜索效率[10]。

此外，為了實現持續學習並確保高階語言（如 LLM 輸出文字指令）能精

確轉換為真實物理世界中的「感知與行動（Perception & Action）」，檢索增強生成（RAG）與情節記憶（Episodic Memory）被導入機器人系統。情節記憶能捕捉多模態的場景脈絡與時序上的事件並詳加記錄，解決傳統使用 API Key 呼叫 LLM 模型無法記住過往操作記錄的缺陷，這對於長時程的無人機任務非常重要，能使系統在任務過程中依據記錄去進行自我修正[11-14]。

(四)研究方法及步驟

我們參考了 Herron 與 Song 等人的分層自主代理架構［15-16］，在本研究計畫中構建了包含共享情報戰情室的三層式架構（如圖一）。Layer 1 以 LLM 為核心大腦，整合讀取 RAG 資料庫、情節記憶資料庫與接收組合 Prompt 進行高階語意推論；Layer 2（Behavior Planner）作為接收輸出訊號轉譯的樞紐，負責將語意決策轉化為具體航點、飛行路徑與環境適應參數；Layer 3（Low-Level Flight Controller）則接收 Layer 2 的訊號，執行底層馬達控制並結合人工勢場法（APF）進行即時避障，如下圖一所示。

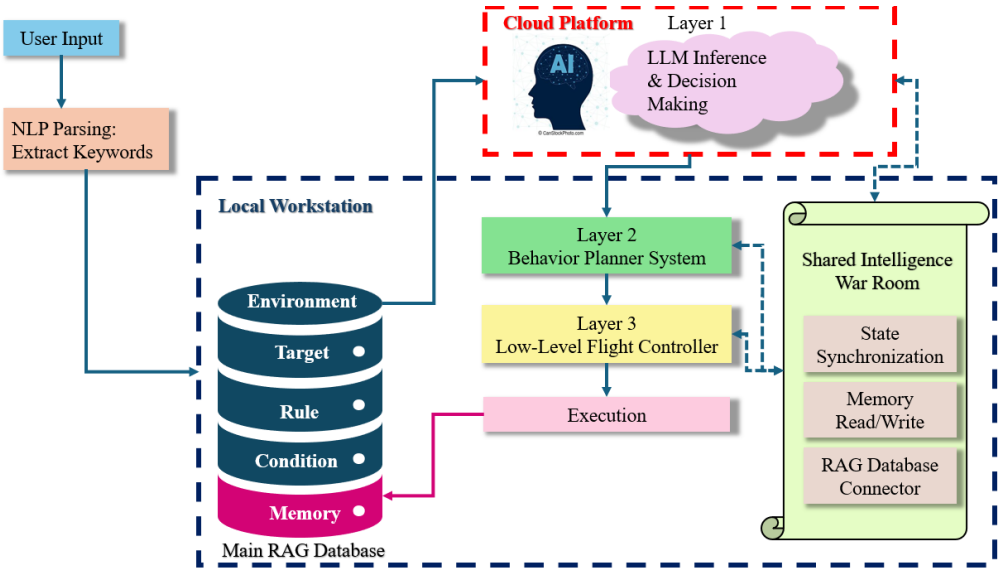

圖一、系統分層架構圖

考量研究之時程與資源，本計畫著重於仿生架構之系統整合驗證，並設定系統對於開發後實際運用於真實無人機的可行性。我們利用純軟體模擬的實驗環境，全程採用 Microsoft AirSim 進行 Software In The Loop 模擬架構，不製作實體無人機，以排除硬體除錯、電池續航與飛安法規之變數，專注於驗證 AI 決策邏輯與自動化系統的研究。另外，對於環境資料庫採用預先標註之靜態語意地圖（Pre-processed Semantic Map），我們不開發即時衛星遙測接收系統，而是重點在於驗證 Layer 1 如何讀取地圖資訊進行決策。在 LLM 的部分，我們專注於 提示工程（Prompt Engineering）與 RAG 檢索演算法的設計與優化，利用現有大模型 OpenAI GPT-4o 為實驗工具。

4.1 Layer 1：結合 RAG 資料庫輸出任務決策

由於硬體與資源配置（System Environment）的限制，我們的研究採用「雲端-本地協同」架構，這樣本地工作站（i5-13420H / RTX 4060 8GB / 32GB RAM）的 GPU 算力可運用於 AirSim 模擬器，確保維持 30Hz 控制頻率；高階決策運算則利用雲端的 LLM API Key 連接至雲端的 GPT-4o，利用其低延遲特性、高 Robustness 與 JSON 輸出能力，避免本地端的 VRAM 出現 Out Of Memory 風險。

RAG 資料庫建置與來源如圖二所示。為確保 Layer 1 決策有依據可尋，本研究針對四大資料庫設計了資料建置流程。環境資料庫：針對原始衛星圖資(Raw Satellite Imagery)先執行「網格切割（Grid Partitioning)」，再由 CNN 分類進行特徵識別，生成語意地圖（Global Semantic Map, JSON 格式：如 Area1=Forest）並存入；目標資料庫：將 User Input 輸入至雲端 LLM 進行初步解析，提取關鍵特徵（如目標顏色、形狀）並自動填入目標架構（Target Schema）中；規則與條件資料庫：採用預先人工設置的 JSON 格式資料，主要內容為飛行時的規則與硬體限制。

RAG 向量檢索機制（RAG Implementation Pipeline）：

為解決 LLM 輸出幻覺與確保執行任務時，飛行控制符合特定條件，本研究使用開源向量資料庫 ChromaDB 建置知識資料庫，導入「精確檢索」之設計，流程如下：

(1) 語意分塊與向量化（Semantic Chunking & Embedding）：我們採用不直接存入長篇文字，而是運用「語意分塊（Semantic Chunking)」策略，將輸入文字拆解為獨立單一的條目(例如將「森林區限高」獨立列為一項)，隨後利用 OpenAI text-embedding-3-small 模型將條目轉為向量嵌入並建立索引，提升檢索結果的相關性與一致性。

(2) 情境感知檢索（Context-Aware Retrieval）：當 Layer 2 回報狀態變化（如 {"Zone": "Forest", "Event": "Obstacle"}），系統將「當前狀態」結合「原始輸入的任務指令」生成混合查詢向量。

(3) Top-K 過濾：執行 Top-K (K=3) 語意搜索並設定相似度閾值（Threshold > 0.75），以過濾相關性低的檢索結果，降低語意雜訊。

(4) 動態提示詞注入（Dynamic Prompt Injection）： 過濾後的關鍵規則將被動態填入 System Prompt 的［Constraints］區塊中，作為生成的約束條件，使模型在產生 JSON 指令時，需同時滿足任務目標、環境與條件等限制，從系統層面去降低產生不符合條件、規則的決策。

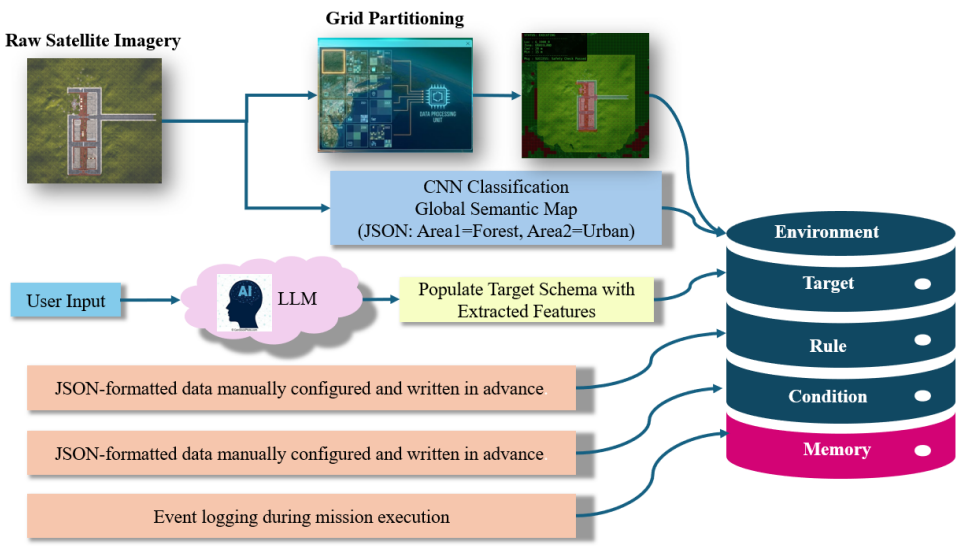

圖二、RAG 資料庫的來源與設置

4.2 Layer 2 Behavior Planner

作為連接高階決策（Layer 1 輸出)與底層控制(Layer 3 Low-Level Flight Controller）的樞紐，Layer 2 Behavior Planner 負責將 Layer 1 所產生的 JSON 決策轉換為具體航點與可執行之飛行路徑規劃。我們參考 Meng 等人（2025)提出之 AuDeRe 架構 [17]，整合三項核心機制來提升系統在任務執行時的穩定性與安全性。

首先，系統執行「指令檢查與資源鎖定」機制，然後再透過地理圍欄（Geofencing）對決策內容進行驗證，以攔截如飛入禁航區或指向不存在區域等不合法指令，降低 Layer 1 輸出高階決策中的錯誤與風險[3-5]。同時，系統利用有限狀態機 (FSM) 的單例模式防止資料傳輸時出現競爭條件 (Race Condition)。其次採用「代碼即規劃（Code-as-Planner）」的設計概念 [7]，將 Layer 1 所輸出的抽象高階決策離散化為具體航點序列，確保高階決策轉為底層控制器執行的操作指令之可行性。最後，設置 10Hz 的即時監控迴圈，持續檢查航點抵達狀態與逾時異常，並在接收到共享情報戰情室回傳之「Target Found」訊號時，即時觸發任務中斷與懸停行為。

此外，考量雲端 API 通訊可能產生延遲或中斷，另設計監測與逾時中斷的機制。當系統於預設時間（如 500ms）內未接收到 Layer 1 的決策更新時，Layer 2 將改由本地情節記憶庫進行檢索，依據歷史路徑與既有狀態執行自主導航或安全懸停，以確保系統於斷網狀態下仍具備基本的自主運作能力。

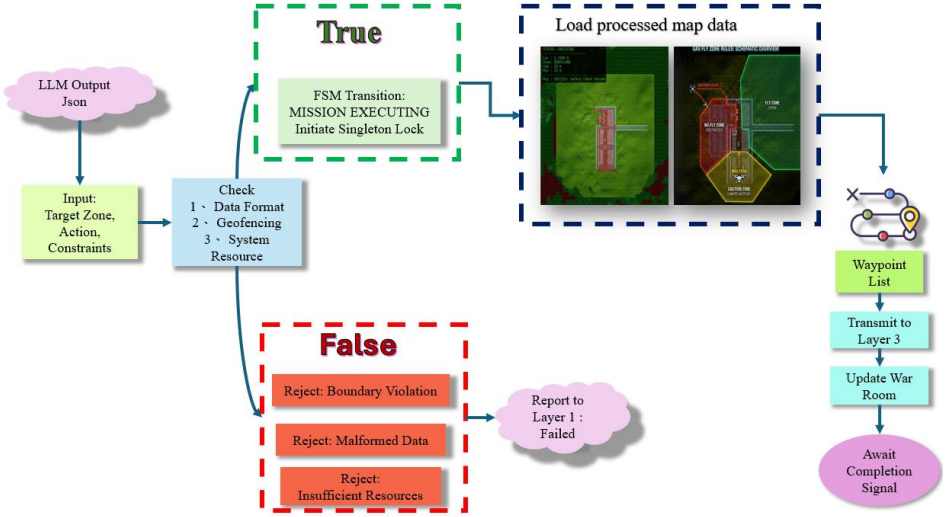

圖三、Layer 2 Behavior Planner 系統在接收 Layer 1 LLM 輸出的 json 格式資料後的完整架構與流程。

4.3 Layer 3：Low-Level Flight Controller

以 30Hz-50Hz 頻率運作，負責將 Layer 2 的航點指令轉化為實際物理動作。參考 Akhihiero 等人（2025）優化向量場跟隨技術［18］與人工勢場法（APF）來計算引力（目標點）與斥力（障礙物），將計算後的力場轉換為速度控制向量（Velocity Vector）驅動無人機。針對如風力等動態干擾因素，引入 Batool 等人（2025）的阻抗控制（Impedance Control）概念［19］以維持飛行穩定，並結合 Bayesian Optimization 自動搜尋最佳 PID 控制參數與阻抗係數，確保無人機在飛行時的穩定度。

4.4 共享情報戰情室與閉環學習機制

共享情報戰情室（Shared Intelligence War Room）：

參考 Fitriawati（2025）與 Marinoni（2006）架構，本研究採用集中式共享記憶體作為跨層級資訊交換機制，採用 Singleton 與 Mutex 建置全域共享記憶體以降低 Layer 2 (10Hz) 與 Layer 3 (30-50Hz) 高頻率的讀寫所產生的競態條件［20-22］。以共享記憶體 (Shared Memory) 取代傳統 IPC，將資料劃分為狀態、感測與指令三大區塊，實現零延遲同步，確保各層級即時存取最新資訊以滿足動態控制需求。

閉環學習機制：

我們參考 Zhang, H.（2025）與 Zhang, B.（2024）的具身智能與語義記憶架構，並採納 DeChant（2025）的風險評估［13-14, 23］，本研究構建模擬生物海馬迴之「情節記憶 RAG」。運作包含兩階段：寫入（Encoding）階段將 Layer 2 偵測到的異常狀態（如避障頻繁、逾時）自動標記為負面標籤並轉化為索引向量；反饋（Retrieval）階段：常態下供 Layer 1 優化決策，通訊中斷時則提供

Layer 2 過去經驗來修正當前行為，實現具備自主學習的無人機系統。

4.5 研究步驟

基於仿生神經分工架構之生成式 AI 自主無人機系統設計與建構，研究步驟 (如圖四) 說明如下:

- 系統開發環境與技術 (System Development Stack)
  1. 軟體核心與通訊協定：基於 Python 3.10 與 AsyncIO 架構來建置地面站，採用 msgpack-rpc 協定與 AirSim 進行低延遲 (<10ms) 通訊，即時處理高併發控制迴圈。
  2. 模擬器環境：利用 AirSim 建構城鎮與野外等多元環境實驗場景，選用四軸 FPV 無人機模型來驗證系統的通用性與可靠度，並透過模擬器裡三維空間的攝像頭以高空俯拍的方式生成模擬的衛星圖資。
  3. 深度學習與感知框架：利用 PyTorch 執行 YOLO World v8L 辨識模型裝載至本地端進行物件辨識，並結合 OpenCV 進行影像前處理與深度圖 (Depth Map) 解析。
  4. 向量資料庫與檢索：部署 ChromaDB 整合 OpenAI text-embedding-3-small 模型，運用 HNSW 演算法達成毫秒級別的語意檢索機制。
- 基礎建設與資料庫建構 (Infrastructure & Data Foundation)
  1. RAG 資料庫建置：

     環境資料庫：在環境資料庫方面，利用 OpenCV 與 ResNet-50 將衛星圖資進行網格切割與分類，生成具有座標之 JSON 語意地圖以建立環境索引；在規則資料庫方面，導入語意分塊 (Semantic Chunking) 技術將飛行 SOP (如限高、禁區) 拆解為單一語意的條目，建立高精度向量檢索機制。

     目標資料庫 (Target DB) 與條件庫 (Condition DB)：定義偵蒐目標特徵模板（支援 LLM 動態特徵生成）以及人工設置硬體設備的數據與資料。
- 分層核心模組開發 (Core Layer Development)
  1. Layer 1 大腦：整合雲端 LLM、Prompt 工程與 RAG 檢索技術將自然語言指令轉化輸出為包含標準化參數與思維鏈的 JSON 決策。
  2. Layer 2 Behavior Planner：開發有限狀態機 (FSM) 與資源鎖定機制以管理狀態，並結合地理圍欄 (Geofencing) 演算法攔截幻覺。開發路徑規劃演算法將抽象決策轉譯為具體的航點列表與路徑規劃。
  3. Layer 3 Low-Level Flight Controller：建立 30-50Hz 高頻控制

迴圈，結合人工勢場法 (APF) 與向量場技術執行即時避障；並引入 Bayesian Optimization 自動搜尋 PID 增益與阻抗係數，解決動態環境下的參數調校，以確保飛行穩定。

- 輔助系統架構 (共享情報戰情室與情節記憶資料庫)

1. 情節記憶資料庫與閉環學習設計：建立向量資料庫(情節記憶資料庫)以儲存關鍵事件日誌（如誤判或發現目標），然後結合寫入 (Encoding) 與檢索 (Retrieval) 機制，讓 Layer 1 在下一次決策時能參考歷史經驗和情節，實現系統具備「經驗累積」與「自我修正」的能力。
2. 共享情報戰情室設置與開發：開發單例模式 (Singleton Pattern) 的記憶體共享區，同時實作互斥鎖 (Mutex) 機制，規劃三大記憶體區塊(包含無人機狀態（座標/姿態）、感測數據（深度/目標訊號）、推論指令（航點/FSM模式），確保 Layer 1~3 資料交換的零延遲與一致性。此外，本研究將基於 Qt 或 Flask 開發可視化的介面，顯示 FSM 狀態、軌跡、剩餘電量與 Layer 1 的決策日誌。
3. 全系統整合與模擬測試：使用 SITL 架構，由本地 Python 地面站透過 AirSim API 擔任控制中樞。感知端以 30Hz 截取數據：深度圖回傳 Layer 3 進行 APF 避障；RGB 影像僅於本地進行物件辨識並上傳「目標發現」訊號至 Layer 1，不傳送影像以確保低延遲。控制端整合 Layer 1 決策、Layer 2 航點與 Layer 3 避障向量，然後 Python 主程式呼叫 API 來驅動無人機。

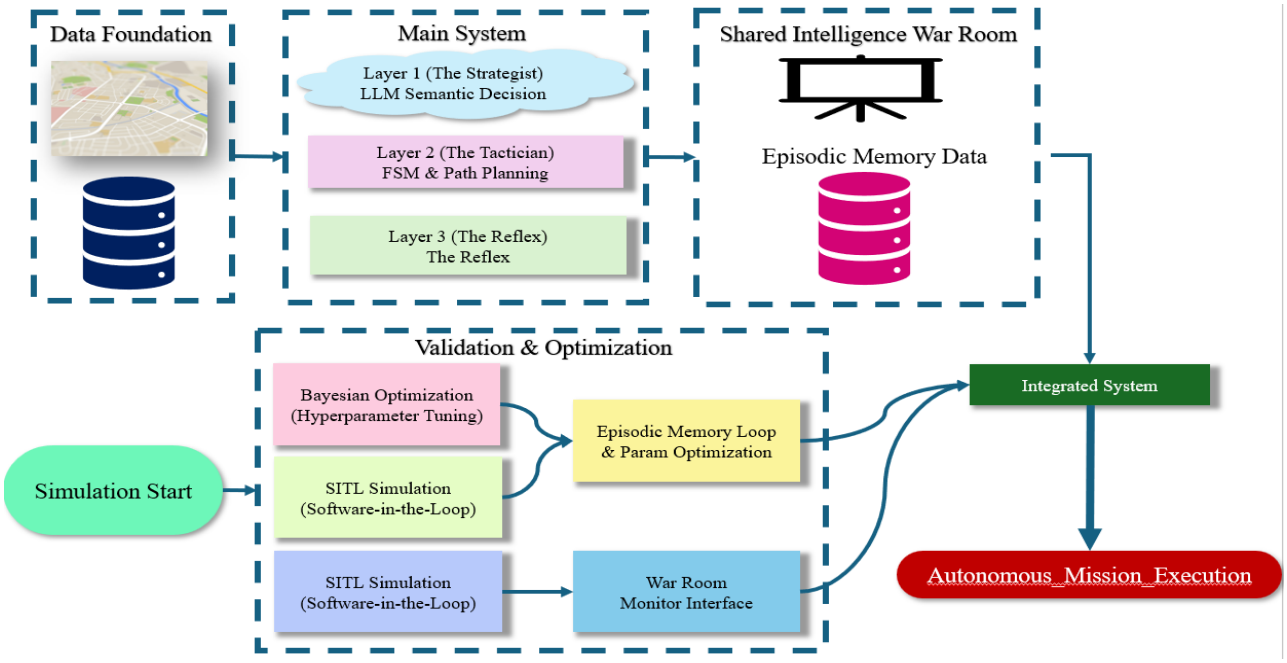

圖四、研究步驟

4.6 研究進度甘特圖

本計畫為期按照時程順利完成，擬定研究進度甘特圖如圖五所示。

月次 / 項目	7月	8月	9月	10月	11月	12月	1月	2月
Layer 1 LLM API Key連接與輸出 JSON 格式								
衛星圖資影像處理和四大資料 RAG 資料庫								
Layer 2 Behavior Planner								
Layer 3 Low-Level Flight Controller								
共享戰情室								
情節記憶資料庫								
系統整合								
整體系統實驗測試								
撰寫成果報告與展示								
預計進度累計百分比	10%	25%	40%	60%	75%	85%	95%	100%

圖五、研究進度甘特圖

4.7 初步結果

本計畫目前已完成將衛星圖資進行區塊分割與特徵擷取(如圖六)，藉由衛星圖資進行區塊分割與特徵擷取之後，在LLM尚未結合四大 RAG 資料庫，只參考使用者輸入任務指令，輸出的推論決策回傳給 Layer 2 Behavior Planner 系統，再由 Layer 2 Behavior Planner 生成飛行路徑與航點(如圖七)。

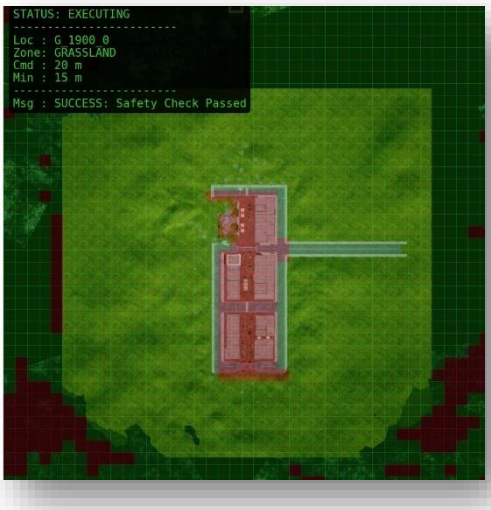

圖六、AirSim 原始 RGB 影像經 CNN 分割後轉換為語意網格地圖，其中綠色表示可飛行區域，紅色表示建築禁航區。

圖七、Layer 2 Behavior Planner 系統再經由語意網格地圖去設置最適當的飛行路徑。

（五）預期結果

本研究預期達成以下具體成果：

5.1 預期技術指標：本研究預期在技術層面上達成多項重要指標：首先在指令執行的可靠度方面，透過 Layer 2 的地理圍欄與 FSM 驗證機制，預期能將錯誤指令與 LLM 幻覺引發的飛行風險降至最低（目標攔截率 > 95%），並建立『Fail-Safe』機制，確保在極端情況下無人機能自動懸停或返航，而非執行錯誤指令；在環境通用性方面，系統能依據 RAG 檢索之環境標籤（如森林或城市）自動切換最佳飛行高度與規劃出最佳飛行路線，實現無需人工介入的全自主執行任務與自適應的能力。此外，藉由情節記憶的導入，無人機在長時間任務中將展現「經驗學習」之智慧化功能，大幅降低重複路徑規劃與誤判率；最終結合 Layer 3 的人工勢場法（APF）控制，即使在複雜或不同的環境中，也能確保即時避障與飛行姿態的穩定 。

5.2 可應用情境：本系統之仿生神經分工架構預期可廣泛應用於高風險或通訊受限之場域。在未知環境搜救（SAR）方面，本系統具備低頻寬高適應性，由於架構設計中需傳輸輕量化 JSON 決策而非高流量影像，即使在森林或災區等網路非最佳情況的環境下，Layer 1 仍能穩定運作；若遭遇完全斷訊，本地端的 Layer 2 與情節記憶庫將即時接管，依據歷史經驗執行自主導航。此外，當感測器回傳模糊資訊（如信心度不足之疑似目標）時，Layer 1 能運用 RAG 內的搜救 SOP 進行邏輯推演，自主下達「降低高度」或「多角度偵查」之決策，而非像傳統無人機直接忽略；在關鍵基礎設施巡檢方面，針對化工廠或離岸風電場，透過將嚴格的工安規範寫入 RAG 規則庫，確保系統在規劃路徑時嚴格遵守設備間的安全距離與禁航區限制，有效降低人為操作風險。

（六）參考文獻

[1] Tian, Y., Lin, F., Li, Y., Zhang, T., Zhang, Q., Fu, X., Huang, J., Dai, X., Wang, Y., Tian, C., Li, B., Lv, Y., Kovács, L., & Wang, F.-Y. (2025). UAVs meet LLMs: Overviews and perspectives toward agentic low-altitude mobility. arXiv. https://doi.org/10.48550/arXiv.2501.02341

[2] Firoozi, R., Tucker, J., Tian, S., Majumdar, A., Sun, J., Liu, W., Zhu, Y., Song, S., Kapoor, A., Hausman, K., Ichter, B., Driess, D., Wu, J., Lu, C., & Schwager, M. (2023). Foundation models in robotics: Applications, challenges, and the future. arXiv. https://doi.org/10.48550/arXiv.2312.07843

[3] Joshi, S. (2025). Mitigating LLM hallucinations: A comprehensive review of techniques and architectures [Preprint]. Preprints.org. https://doi.org/10.20944/preprints202505.1955.v1

[4] Darwish, A. M., Rashed, E. A., & Khoriba, G. (2025). Mitigating LLM hallucinations using a multi-agent framework. Information, 16(7), 517. https://doi.org/10.3390/info16070517

[5] Goel, A., Schwartz, D., & Qi, Y. (2025). Zero-knowledge LLM hallucination detection and mitigation through fine-grained cross-model consistency. Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing: Industry Track. ACL Anthology. https://aclanthology.org/2025.emnlp-industry.139

[6] Yuan, L., Deng, C., Han, D.-J., Hwang, I., Brunswicker, S., & Brinton, C. G. (2025). Next-generation LLM for UAV: From natural language to autonomous flight. arXiv preprint arXiv:2510.21739. https://doi.org/10.48550/arXiv.2510.21739

[7] Chen, Y., Hao, Y., Zhang, Y., & Fan, C. (2025). Code-as-symbolic-planner: Foundation model-based robot planning via symbolic code generation. arXiv preprint arXiv:2503.01700. https://doi.org/10.48550/arXiv.2503.01700

[8] Vorobiov, E., Mahmood, A. J., Rezvani, S., & Chhabra, R. (2025). ARRC: Advanced reasoning robot control—Knowledge-driven autonomous manipulation using retrieval-augmented generation. arXiv preprint arXiv:2510.05547. https://doi.org/10.48550/arXiv.2510.05547

[9] Wu, J., You, H., Sun, B., & Du, J. (2025). LLM-driven pareto-optimal multi-mode reinforcement learning for adaptive UAV navigation in urban wind environments. IEEE Transactions on Intelligent Transportation Systems. https://doi.org/10.1109/ACCESS.2025.3611336

[10] Jin, F., Ye, Z., Li, M., Xiao, H., Zeng, W., & Wen, L. (2025). A new hybrid reinforcement learning with artificial potential field method for UAV target search. Sensors, 25 (9), 2796. https://doi.org/10.3390/s25092796

[11] Chen, Z., Sun, Y., Yan, C., Zhou, H., Xiang, X., & Jiang, J. (2025). Skypilot: Fine-tuning LLM with physical grounding for AAV coverage search. arXiv preprint arXiv:2511.18270. https://doi.org/10.48550/arXiv.2511.18270

[12] Akbar, N. A., Dembani, R., Lenzitti, B., & Tegolo, D. (2025). RAG-driven memory architectures in conversational LLMs—A literature review with insights into emerging agriculture data sharing. IEEE Access, 13, 123855–123880. https://doi.org/10.1109/ACCESS.2025.3589241

[13] Zhang, H., Zhang, Z., Wang, Z., Zhang, Z., Fang, L., Zhou, Q., & Gan, C. (2025). Ella: Embodied social agents with lifelong memory. arXiv preprint arXiv:2506.24019. https://doi.org/10.48550/arXiv.2506.24019

[14] Zhang, B., Wang, T., Li, M., Cui, Y., Lin, X., & Zhu, Z. (2024). Multiple unmanned aerial vehicle (multi-UAV) reconnaissance and search with limited communication range using semantic episodic memory in reinforcement learning. Drones, 8(8), 393. https://doi.org/10.3390/drones8080393

[15] Herron, E., Lee, X. Y., Sin, G., Gonzalez Diaz, T., Farahat, A., & Gupta, C. (2025). A hierarchical agentic framework for autonomous drone-based visual inspection. Proceedings of the Annual Conference of the PHM Society, 17 (1). https://doi.org/10.36001/phmconf.2025.v17i1.4328

[16] Song, H., Yang, Z., Du, H., Zhang, Y., Zeng, J., & He, X. (2025). LLM-LCSA: LLM for collaborative control and decision optimization in UAV cluster security. Drones, 9 (11), 779. https://doi.org/10.3390/drones9110779

[17] Meng, Y., Chen, F., Chen, Y., & Fan, C. (2025). AuDeRe: Automated strategy decision and realization in robot planning and control via LLMs. arXiv preprint arXiv:2504.03015. https://doi.org/10.48550/arXiv.2504.03015

[18] Akhihiero, D., Olawoye, U., & Pereira, G. A. S. (2025). Optimization-based motion planning for vector field following in dynamic environments. Proceedings of the 2025 International Conference on Unmanned Aircraft Systems (ICUAS). https://doi.org/10.1109/ICUAS65942.2025.11007851

[19] Batool, F., Yaqoot, Y., Zafar, M., Khan, R. A., Khan, M. H., Fedoseev, A., & Tsetserukou, D. (2025). ImpedanceGPT: VLM-driven impedance control of swarm of mini-drones for intelligent navigation in dynamic environment. arXiv preprint arXiv:2503.02723. https://doi.org/10.48550/arXiv.2503.02723

[20] Marinoni, M., Facchinetti, T., Buttazzo, G., & Franchino, G. (2006). An embedded real-time system for autonomous flight control. Proceedings of the 50th International Congress of ANIPLA, 1–20.

[21] Fraser, D., Pretorius, A., Hepworth, J., & Botha, N. (2025). Embedded systems design of a low-cost flight controller for use in UAV platforms. MATEC Web of Conferences, 417, 04006. https://doi.org/10.1051/matecconf/202541704006

[22] Fitriawati, M., & Wicaksono, M. F. (2025). Memory efficiency on the Raspberry Pi 3b using the singleton design pattern for murrotal and salawat tarhim application. Proceedings of the 8th International Conference on Informatics, Engineering, Science & Technology (INCITEST 2025). Atlantis Press. https://doi.org/10.2991/978-94-6463-587-4_14

[23] DeChant, C. (2025). Episodic memory in AI agents poses risks that should be studied and mitigated. arXiv preprint arXiv:2501.11739. https://doi.org/10.48550/arXiv.2501.11739